


神经网络

BP神经网络/反向传播神经网络

概述

BP神经网络是一种多层前馈神经网络，特点为信号向前传递，误差反向传递。在向前传递中，出入信号冲输入层经隐含层逐层处理，直至输出层。每层的神经元状态只影响下一层神经元状态。如果输出层得不到期望输出，则转入反向传播，根据预测误差调整网络权重和阈值，从而使BP神经网络预测输出不断逼近期望输出。

BP神



神经网络可以看作一个**非线性函数**，网络输入值和预测值分别为该函数的自变量和因变量。当输入节点数为 n ，输出节点数为 m 时，BP神经网络就表达了从 n 个自变量到 m 个因变量的函数映射关系。

训练BP神经网络步骤

1. 初始化网络，根据系统输入输出序列(X,Y)确定网络输入层节点数 n ，隐藏层节点数 l ，输出层节点数 m ，初始化输入层，隐含层和输出层神经元之间的连接权值 ω_{ij} ， ω_{jk} ，初始化隐含层阈值 a ，输出层阈值 b ，给定学习速率和神经元激励函数。
2. 隐含层输出计算。根据输入向量 X ，输入层和隐含层间的连接权值 ω_{ij} 以及隐含层阈值 a ，计算出隐含层输出 H 。

$$H_i = f\left(\sum_{i=1}^n \omega_{ij}x_i - a_j\right) \quad j = 1, 2, \dots, l$$

其中， f 为隐藏层激励函数

3. 输出层输出计算。根据隐含层输出 H ，链接权值 ω_{jk} 和阈值 b ，计算BP神经网络预测输出 O 。

$$O_k = \sum_{j=1}^i H_j \omega_{jk} - b_k \quad k = 1, 2, \dots, m$$

4. 误差计算。根据网络预测输出 O 和期望输出 Y ，计算网络预测误差 e ，

$$e_k = Y_k - O_k \quad k = 1, 2, \dots, m$$

5. 权值更新。根据网络预测误差 e 更新网络连接权值 ω_{ij} ， ω_{jk} 。

$$\begin{aligned} \omega_{ij} &= \omega_{ij} + \eta H_j (1 - H_j) x(i) \sum_{k=1}^m \omega_{jk} e_k & i = 1, 2, \dots, n; j = 1, 2, \dots, l; \\ \omega_{jk} &= \omega_{jk} + \eta H_j e_k & j = 1, 2, \dots, l; k = 1, 2, \dots, m; \end{aligned}$$

式中 η 为学习速率

6. 阈值更新。根据网络预测误差 e 更新网络节点阈值 a, b 。

$$\begin{aligned} a_j &= a_j + \eta H_j (1 - H_j) \sum_{k=1}^m \omega_{jk} e_k & j &= 1, 2, \dots, l \\ b_k &= b_k + e_k & k &= 1, 2, \dots, m \end{aligned}$$

7. 判断算法迭代是否结束，若未结束，返回步骤二。

隐含层节点数选择

最佳隐藏节点数选择可参考以下公式：

$$\begin{aligned} l &< n - l \\ l &< \sqrt{(m - n)} + a \\ l &= \log_2 n \end{aligned}$$

式中， n 为输入层节点数； l 为隐含层节点数； a 为0—10间的数字。

附加动量法

BP神经网络的采用梯度修正法作为权值和阈值的学习算法，从网络预测误差的负梯度方向修正权值和阈值，没有考虑以前的经验积累，学习过程收敛缓慢，可以采用附加动量的权值学习公式：

$$\omega(k) = \omega(k-1) + \Delta\omega(k) + a[\omega(k-1) - \omega(k-2)]$$

式中 $\omega(k)$ ， $\omega(k-1)$ ， $\omega(k-2)$ 分别为 $k, k-1, k-2$ 时刻的权值， a 为动量学习率。

变学习率学习算法

BP神经网络学习率 η 的取值在[0—1]之间，学习率 η 越大，对权值的修改越大，网络学习速度越快。但过大的学习率 η 会使权值学习过程中产生震荡，过小的学习率使网络收敛过慢，权值难以趋于稳定。变学习率方法是指学习概率 η 在BP神经网络进化初期较大，网络收敛迅速，随着学习过程的进行，学习率不断减小，网络趋于稳定。变学习率计算公式为：

$$\eta(t) = \eta_{max} - t(\eta_{max} - \eta_{min}) - t_{max}$$

式中， η_{max} 为最大学习率； η_{min} 为最小学习率； t_{max} 为最大迭代次数； t 为当前迭代次数

BP神经网络工具箱

newff BP神经网络参数设置函数

`net = newff(P,T,S,TF,BTF,BLF,PF,IPF,OPF,DDF)`

该函数构建了一个BP神经网络，其中：

P :输入数据矩阵

T :输出数据矩阵

S :隐含层节点数

TF :节点传递函数，包括硬限幅传递函数 `hardlim`，对称硬限幅传递函数 `hardlims`，线性传递函数 `purelin`，正切S型传递函数 `tansig`，对数S型传递函数 `logsig`。

BTF :训练函数，包括梯度下降BP算法训练函数 `traingd`；动量反传的梯度下降BP算法训练函数 `traingdm`；动态自适应学习率的梯度下降BP算法训练函数 `traingda`；动量反传和动态自适应学习率的梯度下降BP算法训练函数 `traingdx`；Levenberg-Marquardt 的BP算法训练函数 `trainlm`。

BTF :网络学习函数，包括BP学习规则 `learngd`，带动量项的BP学习规则 `learnngdm`。

其他参数一般采用系统默认参数。

train BP神经网络训练函数

`[net,tr] = train(NET,X,T,Pi,Ai)`

该函数用训练数据训练BP神经网络，其中：

- NET** :待训练网络。
- x** :输入数据矩阵。
- T** :输出数据矩阵

其他参数一般采用系统默认参数。

```
sim BP神经网络预测函数
y = sim(net,x)
```

该函数用训练好的BP神经网络预测函数输出，其中：

- net** :训练好的网络。
- x** :输入数据。
- y** :网络预测数据。

多隐含层BP神经网络

多隐含层泛化能力强，预测精度高，但训练时间长。可以通过 **newff** 函数中的第三个参数构建多隐含层的BP神经网络：

```
net = newff(inputn, outputn, [5,5])
```

该语句构架了双隐含层的BP神经网络，每个隐含层的节点数为5。


节点传递函数

隐含层和输出层函数的选择对BP神经网络预测精度有较大影响。一般隐含层节点传递函数选用 **logsig** 或者 **tansig** 函数，输出层传递函数选择 **tansig** 或 **purelin** 函数

RBF神经网络/径向基神经网络

概述

径向基函数神经网络（Radial Basis Function Neural Network，RBF神经网络）是一类常用的三层前馈网络，既可用于函数逼近，也可用于模式分类。与其他类型的人工神经网络相比，RBF网络有生理学基础，结构简单，学习速度快，优良的逼近性能和泛化能力等特点。



径向基函数的网络结构

RBF

径向基函数是一个取值仅仅依赖于离原点距离的实值函数，也就是 $\phi(x) = \phi(||x||)$,或者还可以是到任意一点 c 的距离， c 点称为中心点，也就是 $\phi(x, c) = \phi(||x - c||)$ 。任意一个满足 $\phi(x) = \phi(||x||)$ 特性的函数 Φ 都叫做径向基函数，标准的一般使用欧氏距离(也叫做欧式径向基函数)。常用的径向基函数包含：

Gaussian 函数

$$\phi(x) = e^{-\frac{r^2}{2\sigma^2}}$$

反常S型函数

$$\phi(x) = \frac{1}{1 + e^{\frac{r^2}{\sigma^2}}}$$

拟多二次函数

$$\phi(x) = \frac{1}{(r^2 + c^2)^{\frac{1}{2}}}$$

变种高斯函数

$$\phi(x) = e^{-\frac{\|x-\mu_t\|^2}{\sigma_t^2}}$$

其中 μ_t 为中心点， σ_t 为径基宽度。径基宽度决定了径向基函数下降的快慢。

RBF神经网络

RBF神经网络的拓扑结构是一种三层前向网络:

1. 输入层由信号源结点构成,仅起到数据信息的传递作用，对输入信息不进行任何变换;
2. 第二层为隐含层，结点数视需要而定，隐含层神经元的核函数(作用函数)为高斯函数，对输入信息进行空间映射变换;
3. 第三层为输出层，它对输入模式做出响应，输出层神经元的作用函数为线性函数，对隐含层神经元输出的信息进行线性加权后输出，作为整个神经网络的输出结果。

由此可知，RBF求解的参数有3个：基函数的中心 μ_t 、方差 σ_t 以及隐含层到输出层的权值 ω_{ij} 。

RBF网络训练流程

1.选择核函数

$$\phi(x_i, c_i) = e^{-\frac{\|x-\mu_t\|^2}{\sigma_t^2}}$$

其中 c_j 为第 i 个神经元的中心; σ 为高斯核的宽度， $\|x_i - c_i\|$ 为样本 x_i 到中心点 c_j 的欧氏距离。

RBF网络定义为：

$$f(x) = \sum_{j=1}^q \omega_j \psi(x, c_j)$$

其中 ω_j 为第 j 个神经元的权重。

2. 定义误差函数为均方误差，目标是为了最小化误差函数：

$$E = \frac{1}{2m} \sum_{i=1}^m e_i^2 = \frac{1}{2m} \sum_{i=1}^m (f(x) - y)^2 = \frac{1}{2m} \sum_{i=1}^m (\sum_{j=1}^q \omega_j \psi(x, c_j) - y)^2$$

利用BP算法反向传播误差，并利用梯度下降法分别求得RBF网络参数优化的方向。

3. 输出层的神经元线性权重迭代公式

$$\Delta \omega = \frac{\delta E}{\delta \omega} = \frac{1}{m} \sum_{i=1}^m (f(x) - y) \psi(x, c) = \frac{1}{m} \sum_{i=1}^m e_i \psi(x, c)$$

$$\omega_{k+1} = \omega_k - \eta \Delta \omega$$

4.隐含层的神经元中心点迭代公式

$$\Delta c_j = \frac{\delta E}{c_j} = \frac{1}{m\sigma_j^2} \sum_{i=1}^m (f(x) - y) \omega \psi(x, c_j) (x - c_j)$$

$$c_{k+1} = c_k - \eta \Delta c$$

5. 隐含层的高斯核宽度迭代公式

$$\Delta \delta_j = \frac{\delta E}{\delta_j} = \frac{1}{m\delta_j^3} \sum_{i=1}^m (f(x) - y) \omega \psi(x, c_j) \|x_i - c_j\|^2$$

$$\delta_{k+1} = \delta_k - \eta \Delta \delta$$

6. 对RBF中不同的参数分别设置不同的学习率，经过多轮迭代直至误差函数收敛，结束训练